

# Ingeniería de características para series epidemiológicas semanales jerárquicas

## Resumen ejecutivo

El conjunto de datos descrito —conteos epidemiológicos semanales organizados por **departamento** → **provincia** → **distrito**, complementados con KPI y filtros extraídos de una aplicación Shiny— tiene una estructura especialmente adecuada para modelos de pronóstico globales o jerárquicos. Su principal fortaleza no está únicamente en el número de casos observado en cada semana, sino en la posibilidad de representar simultáneamente **memoria temporal, estacionalidad, velocidad de crecimiento, contexto poblacional, dependencia espacial y señales provenientes de niveles geográficos superiores**. La literatura de pronóstico epidemiológico muestra que los antecedentes recientes de vigilancia suelen constituir algunos de los predictores más fuertes a horizontes cortos, mientras que clima, movilidad y relaciones espaciales pueden aportar información adicional cuando se incorporan con retardos y sin utilizar información futura. En un estudio directamente relevante para Perú, Benedum et al. modelaron casos semanales de dengue en Iquitos utilizando vigilancia y variables meteorológicas para horizontes de 4–12 semanas; en predicciones cercanas, la información de vigilancia resultó especialmente valiosa. <sup>1</sup>

La primera recomendación es **ampliar la extracción a varios años** si el dataset actualmente conserva únicamente 2025. Una serie de 52 o 53 observaciones por distrito permite construir retardos cortos y ventanas móviles, pero es insuficiente para estimar de forma sólida una estacionalidad anual: `lag_52`, una descomposición STL con periodo 52 o una estructura Fourier anual tendrían como máximo una repetición completa del ciclo. Los trabajos de descomposición estacional y forecasting epidemiológico normalmente estiman los patrones a partir de múltiples ciclos temporales; MSTL, STL y TBATS están específicamente diseñados para separar tendencia y componentes periódicos a partir de patrones repetidos. <sup>2</sup>

Para este dataset, un conjunto inicial de alto valor debería incluir **retardos de casos** en 1, 2, 3, 4, 6, 8, 12, 13 y, si existe suficiente historia, 26 y 52 semanas; **estadísticos móviles** de 2, 4, 8, 12/13 y 26 semanas; diferencias y tasas de crecimiento; incidencia por 100 000 habitantes; términos Fourier; indicadores robustos de anomalía; variables meteorológicas retrasadas; y agregaciones de distritos vecinos y de la provincia a la que pertenece cada distrito. Los modelos de retardos distribuidos muestran precisamente que los efectos de exposiciones epidemiológicamente relevantes pueden repartirse a lo largo de diversos retardos, y advierten que incluir muchos lags individuales altamente correlacionados sin regularización genera inestabilidad. <sup>3</sup>

Una segunda recomendación crítica es aplicar una política de **“past-only features”**: para pronosticar la semana  $t + h$ , cada variable debe poder conocerse en la fecha de origen  $t$ . Por ejemplo, una media móvil debe calcularse sobre `casos.shift(1)` y no incluir el dato que se desea predecir; los KPI del Shiny solo deberían utilizarse cuando representen información disponible en el origen de la predicción; y el total provincial debe retrasarse o transformarse en una señal *leave-one-out* para evitar que el caso distrital objetivo aparezca implícitamente dentro de su propio predictor provincial. Este control es esencial porque la

evaluación convencional puede ser optimista cuando el proceso de selección, transformación o validación utiliza información que temporalmente pertenece al futuro. 4

Una tercera recomendación es **no modelar los códigos geográficos como números continuos**. Los identificadores de departamento, provincia y distrito son categorías. Para modelos lineales pueden utilizarse efectos fijos, one-hot encoding o efectos jerárquicos; para boosting con elevada cardinalidad, CatBoost ofrece estadísticas categóricas ordenadas diseñadas para reducir el *target leakage* que puede aparecer con el target encoding convencional. Para modelos probabilísticos, el pooling parcial espacial y jerárquico basado en modelos tipo BYM/BYM2 permite compartir información entre áreas sin asumir que todos los distritos presentan el mismo riesgo. 5

Finalmente, la **validación debe reproducir el uso real del modelo**. El esquema recomendado es *rolling-origin* o *expanding window*, con todos los distritos cortados en las mismas fechas. La selección de hiperparámetros y características debe realizarse en un bucle temporal interno, manteniendo un conjunto externo posterior completamente intacto. Para series no estacionarias, Cerqueira, Torgo y Mozetič encontraron que las evaluaciones que preservan el orden temporal, particularmente los holdouts repetidos en distintos periodos, proporcionan estimaciones más fiables que esquemas de validación que mezclan temporalmente las observaciones. 6

#### Orden de prioridad recomendado para este proyecto:

| Prioridad   | Familia                                             | Motivo principal                                                           |
|-------------|-----------------------------------------------------|----------------------------------------------------------------------------|
| Muy alta    | Lags + rolling + crecimiento                        | Capturan directamente la dinámica epidémica reciente                       |
| Muy alta    | Incidencia poblacional + jerarquía geográfica       | Hace comparables distritos de tamaños distintos                            |
| Muy alta    | Estacionalidad Fourier/ calendario                  | Captura ciclos anuales sin inflar demasiado la dimensionalidad             |
| Alta        | Clima con retardos distribuidos                     | Epidemiológicamente plausible y útil en enfermedades vectoriales           |
| Alta        | Lags espaciales y provincia<br><i>leave-one-out</i> | Capturan propagación regional y contexto epidémico                         |
| Alta        | Indicadores de anomalía/ cambio                     | Identifican inicio y aceleración de brotes                                 |
| Media-alta  | Tendencia STL/MSTL                                  | Útil con varios años de historia                                           |
| Media       | KPI Shiny                                           | Útiles solamente después de comprobar disponibilidad y ausencia de leakage |
| Condicional | Imputación avanzada BRITS/ SAITS                    | Más apropiada para paneles multivariados con faltantes sustanciales        |

| Prioridad   | Familia                                      | Motivo principal                                               |
|-------------|----------------------------------------------|----------------------------------------------------------------|
| Condicional | <code>lag_52</code> , ventanas de 52 semanas | Requieren varios años de datos para ser realmente informativas |

## Diseño del problema y principios de construcción

La representación más conveniente es un **panel espacio-temporal en formato largo**, con una fila por unidad geográfica y semana. Conceptualmente:

$$Y_{i,t} = \text{casos observados en el distrito } i \text{ durante la semana } t.$$

Cada registro debería contener, como mínimo:

$$(\text{departamento, provincia, distrito, año, semana, } Y_{i,t})$$

y posteriormente enriquecerse con población, coordenadas o geometría del distrito, clima y demás covariables. Las estimaciones y proyecciones de población a nivel nacional, departamental, provincial y distrital están disponibles a través del INEI, por lo que constituyen la fuente natural para construir tasas de incidencia comparables entre territorios peruanos. <sup>7</sup>

Para un horizonte  $h$ , el problema de pronóstico debe formularse como:

$$Y_{i,t+h} = f(X_{i,t}, X_{i,t-1}, X_{i,t-2}, \dots),$$

no como:

$$Y_{i,t+h} = f(X_{i,t+h}).$$

La diferencia es fundamental: la segunda expresión podría estar introduciendo información que todavía no existe en el momento de hacer el pronóstico. La literatura sobre evaluación temporal muestra que preservar el orden cronológico es especialmente importante ante no estacionariedad, cambios de régimen y dependencia serial. <sup>8</sup>

En datos de vigilancia, además, **cero y dato faltante no son equivalentes**. Un cero significa que se conoce el número de casos y este fue cero; un dato faltante puede representar ausencia de reporte, retraso de notificación, error de extracción o pérdida de la covariable. Las arquitecturas diseñadas específicamente para series incompletas, como GRU-D, BRITS y SAITS, parten precisamente de que el patrón de ausencia puede contener información y no debería eliminarse automáticamente mediante una imputación indiscriminada. <sup>9</sup>

Otro elemento distintivo del dataset es su jerarquía. Para cada distrito existen al menos dos contextos naturales:

$$\text{distrito} \subset \text{provincia} \subset \text{departamento}.$$

En consecuencia, no conviene tratar cada serie de manera completamente independiente. Los modelos epidemiológicos espacio-temporales y la literatura de reconciliación jerárquica muestran ventajas

conceptuales de combinar información local y agregada y de imponer coherencia entre niveles. MinT, por ejemplo, fue desarrollado para reconciliar pronósticos de series jerárquicas de manera que las predicciones inferiores sumen correctamente a sus agregados. <sup>10</sup>

Esto tiene una implicación particularmente importante para los KPI extraídos del Shiny. Un KPI puede ser una característica válida solo cuando:

$\text{timestamp de disponibilidad del KPI} \leq \text{timestamp de origen del forecast}.$

Si el KPI representa, por ejemplo, el total de casos del mismo periodo que se pretende predecir, utilizarlo sería leakage. Si representa el acumulado hasta la semana anterior, puede convertirse en una característica legítima. Por ello conviene almacenar junto con cada KPI no solo su valor, sino su **definición, nivel geográfico, periodo de referencia y fecha en que se conoció**.

Una arquitectura lógica para el dataset sería:

```
geo_id
departamento
provincia
distrito
anio
semana
fecha_inicio_semana
casos
poblacion
incidencia_100k

+ lags
+ rolling features
+ estacionalidad
+ crecimiento
+ acumulados
+ anomalías
+ clima
+ movilidad
+ intervenciones
+ lags espaciales
+ variables jerárquicas
+ KPI válidos
```

La separación entre **variable observada, momento de observación y momento de disponibilidad** debe mantenerse de forma explícita, sobre todo cuando se incorporen datos meteorológicos, movilidad o información administrativa. Los trabajos recientes de forecasting de dengue que integran vigilancia, clima y movilidad dependen precisamente de esa correcta alineación temporal. <sup>11</sup>

## Ingeniería temporal y epidemiológica

**Retardos simples y distribuidos.** Un lag representa el valor histórico:

$$L_k(t) = Y_{t-k}.$$

En epidemiología es una de las variables más naturales porque la incidencia actual depende de la intensidad reciente de transmisión, y múltiples exposiciones pueden tener efectos que se manifiestan después de varios periodos. Los modelos DLM y DLNM formalizan justamente este problema: en lugar de asumir que una exposición actúa únicamente en  $t$ , permiten distribuir su efecto entre  $t, t-1, \dots, t-L$ . Gasparrini señala además que estimar un coeficiente completamente independiente para cada lag puede ser ineficiente debido a la fuerte correlación entre retardos adyacentes, motivo por el que se utilizan restricciones, splines o bases de baja dimensión. <sup>12</sup>

Para los **casos epidemiológicos**, propongo como espacio inicial:

$$k \in \{1, 2, 3, 4, 6, 8, 12, 13, 26, 52\}.$$

Los retardos 1–4 capturan persistencia inmediata; 6–13 permiten observar tendencias de aproximadamente uno a tres meses; 26 permite contrastar medio año y 52 el mismo periodo del año anterior. Este rango es una propuesta de búsqueda para el dataset, no una regla epidemiológica universal, y debe seleccionarse dentro de la validación temporal. Los estudios de dengue de Iquitos y de sistemas con clima/movilidad confirman el valor predictivo de antecedentes semanales de vigilancia y de covariables retrasadas a horizontes de varias semanas. <sup>13</sup>

El principal peligro es `lag_52`: **con solo 2025 prácticamente no existe información utilizable para construirlo**. Para explotar esta señal sería preferible disponer de al menos 3–5 años, no porque exista una frontera matemática en ese número, sino porque se necesitan varios ciclos independientes para distinguir un patrón anual recurrente de una anomalía puntual. La literatura de STL/MSTL y de estacionalidades complejas depende de la repetición de esos patrones. <sup>14</sup>

**Características de ventana móvil.** Para una ventana  $w$ , una media causal se define como:

$$\bar{Y}_{t,w} = \frac{1}{w} \sum_{j=1}^w Y_{t-j}.$$

Es esencial el límite  $t-1$ : si se incluye  $Y_t$  y el objetivo también depende de  $Y_t$ , puede introducirse información indebida. En DLM, una media móvil de exposiciones puede interpretarse como un caso especial de modelo de retardo distribuido, mientras que modelos modernos de series temporales utilizan representaciones simultáneas de patrones locales de corto plazo y dependencias largas. <sup>15</sup>

Para el panel semanal conviene explorar:

$$w \in \{2, 4, 8, 12, 13, 26, 52\}.$$

Por ventana, las estadísticas candidatas son:

mean, median, std, min, max,  $Q_{0.25}$ ,  $Q_{0.75}$ , sum.

La mediana y el rango intercuartílico son especialmente útiles para construir medidas robustas ante brotes extremos. No conviene generar todas las combinaciones automáticamente si existe poca historia: siete ventanas por ocho agregaciones ya producirían 56 variables altamente correlacionadas por distrito. El problema de colinealidad entre predictores temporalmente próximos es conocido en modelos de retardos y debe tratarse mediante regularización o bases de dimensión reducida. <sup>16</sup>

**Estacionalidad y periodicidad.** La semana epidemiológica puede representarse como una categoría, pero para un ciclo anual resulta más parsimonioso utilizar codificación cíclica:

$$\sin 52_t = \sin \left( \frac{2\pi t}{52.18} \right), \quad \cos 52_t = \cos \left( \frac{2\pi t}{52.18} \right).$$

Una representación Fourier general utiliza:

$$\sin \left( \frac{2\pi kt}{P} \right), \quad \cos \left( \frac{2\pi kt}{P} \right), \quad k = 1, \dots, K.$$

TBATS utiliza representaciones trigonométricas para estacionalidades complejas, mientras que STL y su extensión MSTL descomponen series en tendencia, estacionalidad y residuo; MSTL amplía explícitamente STL a múltiples periodicidades. <sup>17</sup>

Para datos semanales, sugiero inicialmente  $P \approx 52.18$  y  $K = 1-6$ , seleccionando  $K$  mediante validación. Con pocas observaciones comenzaría con  $K = 1-3$ . Más armónicos permiten representar picos estacionales estrechos pero aumentan varianza y riesgo de sobreajuste. Si se dispone de una fecha epidemiológica oficial es preferible derivar la periodicidad de ella y no asumir que la numeración 1-52 se comporta idénticamente todos los años, puesto que pueden existir años con semana 53.

Puede mantenerse también una variable `semana_epidemiologica` categórica, aunque tiene mayor dimensionalidad. Para modelos arbóreos resulta útil; para modelos lineales, Fourier suele ser más eficiente cuando se espera una estacionalidad suave. La selección automática ARIMA y los modelos trigonométricos constituyen referencias metodológicas consolidadas para combinar dependencia autoregresiva y periodicidad. <sup>18</sup>

**Velocidad, crecimiento y aceleración.** La primera diferencia:

$$\Delta Y_t = Y_{t-1} - Y_{t-2}$$

mide la velocidad reciente del proceso. La segunda diferencia:

$$\Delta^2 Y_t = (Y_{t-1} - Y_{t-2}) - (Y_{t-2} - Y_{t-3})$$

aproxima su aceleración. En epidemias, la velocidad de crecimiento contiene información sobre la fase epidémica; existe una relación formal entre tasas de crecimiento y números reproductivos que depende del intervalo generacional, y métodos como EpiEstim utilizan series de incidencia histórica para inferir cambios temporales en transmisión. <sup>19</sup>

Una tasa porcentual simple,

$$g_t = \frac{Y_{t-1} - Y_{t-2}}{Y_{t-2}},$$

es problemática cuando  $Y_{t-2} = 0$ , situación común en distritos pequeños. Dos alternativas más estables son:

$$g_t^{(\log)} = \log(1 + Y_{t-1}) - \log(1 + Y_{t-2})$$

y

$$g_{t,k}^{(c)} = \left( \frac{Y_{t-1} + c}{Y_{t-k-1} + c} \right)^{1/k} - 1,$$

con un  $c$  pequeño, por ejemplo 0.5 o 1. Para este dataset probaría diferencias a 1, 2, 4 y 8 semanas, y tasas compuestas en ventanas de 2, 4 y 8 semanas. Los indicadores de crecimiento deben entenderse como señales predictivas y no como sustitutos directos del número reproductivo, cuya interpretación epidemiológica requiere supuestos sobre intervalos de generación y proceso de transmisión. <sup>20</sup>

**Tasas, ratios e incidencia.** El conteo bruto mezcla dos fenómenos:

tamaño poblacional + riesgo epidemiológico.

Una transformación básica es:

$$I_{i,t} = \frac{Y_{i,t}}{N_{i,t}} \times 100\,000,$$

donde  $N_{i,t}$  es la población del distrito. El INEI mantiene estimaciones y proyecciones poblacionales a nivel departamental, provincial y distrital, por lo que el denominador puede integrarse de manera reproducible al panel. <sup>7</sup>

Para modelos de conteos Poisson o binomial negativo es frecuentemente preferible conservar  $Y_{i,t}$  como respuesta e incluir:

$$\log(N_{i,t})$$

como *offset*, en vez de transformar toda la respuesta en tasa. Los modelos espacio-temporales de enfermedades infecciosas y los modelos de mapeo de riesgo utilizan precisamente estructuras poblacionales y espaciales para separar heterogeneidad territorial de variación epidémica. <sup>21</sup>

Además de `incidencia_100k`, recomiendo:

$$\frac{I_{t-1}}{I_{t-2} + \epsilon}, \quad I_{t-1} - I_{t-2}, \quad \frac{\text{casos distrito}}{\text{casos provincia}}$$

siempre retrasando adecuadamente numerador y denominador. En áreas con población muy pequeña, estas tasas pueden volverse extremadamente volátiles; el pooling jerárquico o espacial ayuda a estabilizar las estimaciones. <sup>22</sup>

**Acumulados.** Una variable acumulativa causal puede escribirse:

$$C_{i,t}^{YTD} = \sum_{j < t, \text{year}(j) = \text{year}(t)} Y_{i,j}.$$

El desplazamiento `<t` vuelve a ser esencial. El acumulado puede representar aproximadamente la fase e intensidad de una temporada epidémica, pero también está fuertemente correlacionado con el número de semanas transcurridas. Por ello resulta conveniente utilizarlo conjuntamente con semana del año, incidencia poblacional y acumulados móviles. Los sistemas de vigilancia y métodos de inferencia epidémica explotan explícitamente la historia previa de incidencia para evaluar cambios en intensidad o detectar brotes. <sup>23</sup>

Además de `casos_acumulados_anio`, resultan más estacionarias:

$$C_{4,t} = \sum_{j=1}^4 Y_{t-j},$$

$$C_{8,t} = \sum_{j=1}^8 Y_{t-j},$$

y

$$R_{4/4,t} = \frac{\sum_{j=1}^4 Y_{t-j} + c}{\sum_{j=5}^8 Y_{t-j} + c}.$$

El último ratio pregunta si las cuatro semanas más recientes superan a las cuatro anteriores y actúa como una medida suave de aceleración. Probaría ventanas 4, 8, 12/13 y 26. Los acumulados anuales deben utilizarse con cautela porque el reinicio en enero introduce una discontinuidad puramente administrativa.

**Anomalías y picos.** Para vigilancia epidemiológica resulta útil construir una puntuación robusta respecto a la historia local:

$$z_t^{rob} = \frac{Y_{t-1} - \text{median}(Y_{t-w:t-2})}{1.4826 \text{MAD}(Y_{t-w:t-2}) + \epsilon}.$$

Puede acompañarse con indicadores:

$$1(z_t^{rob} > 2.5), \quad 1(z_t^{rob} > 3),$$

o con ratios respecto al máximo móvil. Los algoritmos de Farrington mejorados fueron desarrollados para detección automática de brotes en sistemas de vigilancia, mientras que PELT y los métodos bayesianos online permiten identificar cambios estructurales en secuencias temporales. <sup>24</sup>

Como espacio inicial de búsqueda recomendaría baseline de 8–26 semanas para detectar cambios rápidos y, cuando existan varios años, baselines de 52–156 semanas para comparar contra estacionalidad histórica. Umbrales de  $z = 2.5$ –3.5 pueden explorarse como hiperparámetros predictivos y no deberían interpretarse automáticamente como umbrales epidemiológicos oficiales. Una alarma estadística no equivale necesariamente a una definición formal de brote. Los sistemas especializados de vigilancia calibran explícitamente sus umbrales y baselines. <sup>25</sup>

**Puntos de cambio y descomposición de tendencia.** STL representa:

$$Y_t = T_t + S_t + R_t,$$

con tendencia  $T_t$ , componente estacional  $S_t$  y residuo  $R_t$ . MSTL generaliza esta idea a múltiples estacionalidades, mientras TBATS utiliza componentes trigonométricos y errores autoregresivos para patrones complejos. <sup>26</sup>

Como features pueden emplearse:

```
trend_lag1
trend_slope_4w
seasonal_component_lag1
remainder_lag1
remainder_robust_z
weeks_since_last_changepoint
changepoint_last_4w
```

Con datos semanales y varios años utilizaría periodo anual 52/53 para STL, con modo robusto ante brotes. Para detectar cambios estructurales exploraría PELT con penalización seleccionada dentro de la validación o BOCPD con una duración esperada de régimen, por ejemplo, entre 13 y 104 semanas como rango inicial. PELT fue diseñado para localizar múltiples cambios de manera computacionalmente eficiente; BOCPD estima online la probabilidad de que haya ocurrido un cambio, y extensiones recientes han trabajado su robustez y escalabilidad. <sup>27</sup>

Existe aquí un riesgo de leakage especialmente importante: **descomponer la serie completa antes del train/test split permite que observaciones futuras influyan en la tendencia estimada en semanas pasadas**. STL/MSTL y la detección de changepoints deben ajustarse dentro de cada ventana de entrenamiento o implementarse en una versión estrictamente causal. La misma regla se deriva del principio general de evaluación temporal que preserva el orden cronológico. <sup>28</sup>

**Características autoregresivas y PACF.** Un modelo  $AR(p)$  representa:

$$Y_t = c + \sum_{j=1}^p \phi_j Y_{t-j} + \epsilon_t.$$

En feature engineering, esto equivale a suministrar al modelo los retardos relevantes de  $Y$ . La función de autocorrelación parcial puede utilizarse como diagnóstico para identificar órdenes autoregresivos candidatos, mientras que procedimientos automáticos como los de Hyndman y Khandakar seleccionan

estructuras ARIMA mediante búsqueda sistemática. Modelos híbridos modernos como LSTNet también incorporan explícitamente un componente autoregresivo junto a representaciones no lineales de corto y largo plazo. <sup>29</sup>

Para datos semanales propondría evaluar:

$$p = 1, \dots, 8$$

y ampliar hasta 12–13 si la PACF de los conjuntos de entrenamiento lo justifica. Un término estacional AR a 52 semanas solo debería evaluarse con varios años de historia. La PACF debe calcularse **dentro del training fold**, no una sola vez utilizando toda la serie. En distritos con muchos ceros, es además conveniente comparar AR sobre `log1p(casos)` con modelos de conteo directamente sobre casos, dado que la distribución de conteos puede desviarse considerablemente de la Gaussianidad. Los modelos epidemiológicos de conteos suelen emplear familias Poisson sobredispersas u otras distribuciones específicas para conteos. <sup>30</sup>

## Covariables externas, espaciales y jerárquicas

**Meteorología, movilidad, intervenciones y calendario.** En enfermedades transmitidas por vectores como dengue, la meteorología es una fuente natural de covariables; sin embargo, no debería suponerse que la temperatura o precipitación de una única semana tienen un efecto instantáneo y lineal. Los DLNM fueron precisamente desarrollados para representar relaciones no lineales cuyo efecto se distribuye entre distintos retardos. En Iquitos, Benedum et al. incorporaron vigilancia semanal y meteorología a modelos de pronóstico de dengue; estudios recientes también han combinado clima con movilidad humana y antecedentes de casos. <sup>31</sup>

Para cada variable  $X_t$ , por ejemplo temperatura, humedad o lluvia, probaría:

$$X_{t-1}, X_{t-2}, \dots, X_{t-12},$$

más:

$$\begin{aligned} &mean(X_{t-1:t-4}), \quad mean(X_{t-1:t-8}), \quad mean(X_{t-1:t-12}), \\ &max, \min, sum, std \end{aligned}$$

cuando epidemiológicamente tenga sentido. Para clima podría ampliarse el lag máximo hasta 16 semanas como parte de la búsqueda. Para lluvia, la suma puede ser más interpretable que la media; para temperatura, media, mínimo, máximo y amplitud térmica pueden aportar señales distintas. La alta correlación entre clima retrasado semana a semana vuelve especialmente apropiados DLM/DLNM o regularización. <sup>3</sup>

Un punto operacional decisivo es que para un forecast  $h$  semanas hacia adelante **no puede usarse el clima realmente observado durante esas  $h$  semanas futuras**. Deben emplearse valores meteorológicos ya observados al origen, pronósticos meteorológicos que estuvieran disponibles en ese momento, o escenarios explícitos. De otro modo se mediría una capacidad predictiva que no existiría en producción. El mismo principio se aplica a movilidad e intervenciones. <sup>32</sup>

Para movilidad, una construcción útil es:

$$M_{i,t} = \sum_{j/ = i} w_{ji,t} I_{j,t-1},$$

donde  $w_{ji,t}$  representa flujo de personas desde  $j$  hacia  $i$ . Los trabajos de modelado espacial de enfermedades infecciosas y forecasting de dengue muestran que la conectividad puede aportar información que no está contenida únicamente en la vecindad geográfica inmediata. <sup>33</sup>

Las intervenciones pueden codificarse como:

$$intervention_t \in \{0, 1\},$$

$$weeks\_since\_intervention_t,$$

y mediante variables tipo pulso para campañas breves. Vacaciones, feriados o cierres administrativos pueden introducirse como indicadores y posteriormente interactuar con retrasos de reporte. Dado que estas variables pueden reflejar tanto transmisión como cambios en el proceso de notificación, deben interpretarse con prudencia.

**Características espaciales.** Sea  $W = [w_{ij}]$  una matriz de vecindad. Un lag espacial causal es:

$$SL_{i,t} = \sum_j w_{ij} Y_{j,t-1}.$$

Pueden definirse pesos por contigüidad territorial, inverso de distancia, kernel de distancia o flujos de movilidad. Los modelos endémico-epidémicos de Meyer y Held incorporan explícitamente propagación entre regiones y muestran la utilidad de funciones de decaimiento espacial tipo power law en datos agregados de enfermedades infecciosas. <sup>34</sup>

Por distrito, las variables más interesantes serían:

$$neighbor\_mean_{t-1}, \quad neighbor\_sum_{t-1}, \quad neighbor\_max_{t-1},$$

$$neighbor\_incidence_{t-1}, \quad neighbor\_growth_{t-1},$$

y versiones retrasadas 1–4 semanas. En lugar de un único criterio espacial, puede compararse contigüidad frente a distancia o movilidad. Para un kernel por distancia:

$$w_{ij} \propto d_{ij}^{-\rho}$$

o

$$w_{ij} = e^{-d_{ij}/\lambda}.$$

Como búsqueda inicial,  $\rho$  puede evaluarse aproximadamente entre 0.5 y 3, o  $\lambda$  sobre diferentes escalas de distancia determinadas por la distribución real entre centroides. Lo correcto es estimarlos o seleccionarlos temporalmente, no fijarlos únicamente por conveniencia. Las formulaciones power-law tienen respaldo directo en modelos de propagación de enfermedades infecciosas. <sup>35</sup>

Existe una diferencia fundamental entre:

$$WY_t$$

y

$$WY_{t-1}.$$

Para pronosticar desde el final de la semana  $t - 1$ , el segundo suele ser operacionalmente válido; el primero puede ser imposible porque requiere conocer simultáneamente los casos de todos los vecinos en la semana objetivo.

**Jerarquía departamento-provincia-distrito.** Una característica muy valiosa en este dataset es la incidencia reciente del nivel superior:

$$P_{p,t-1} = \sum_{i \in p} Y_{i,t-1}.$$

No obstante, para predecir el distrito  $i$  recomiendo además construir:

$$P_{p,t-1}^{(-i)} = P_{p,t-1} - Y_{i,t-1}.$$

Esta variable *leave-one-out* responde a “¿qué está ocurriendo en el resto de la provincia?” sin duplicar directamente la señal del distrito objetivo. El mismo principio puede utilizarse a nivel departamental.

Features recomendadas:

```
province_cases_other_lag1
province_cases_other_lag4
province_incidence_other_lag1
department_cases_other_lag1
district_share_of_province_lag1
district_vs_province_growth
province_rolling_mean_4
department_rolling_mean_4
```

Los enfoques de pooling espacial BYM/BYM2 y los modelos de propagación regional justifican compartir información entre áreas, mientras que la literatura de forecast reconciliation proporciona un marco formal para mantener coherencia entre predicciones de distintos niveles geográficos. <sup>36</sup>

En modelos probabilísticos o globales conviene incluso considerar **partial pooling**:

$$\alpha_i \sim N(\alpha_{\text{provincia}(i)}, \sigma_d^2),$$
$$\alpha_p \sim N(\alpha_{\text{departamento}(p)}, \sigma_p^2),$$

de manera que distritos con poco historial se acerquen parcialmente al comportamiento de su provincia sin quedar obligados a ser idénticos. BYM y su reformulación escalada BYM2 fueron diseñados para combinar heterogeneidad no estructurada y dependencia espacial en mapeo de enfermedades. <sup>37</sup>

Tras generar pronósticos independientes, puede añadirse una fase de **reconciliación jerárquica** para asegurar:

$$\hat{Y}_{\text{provincia}} = \sum_{d \in \text{provincia}} \hat{Y}_d$$

y

$$\hat{Y}_{\text{departamento}} = \sum_p \hat{Y}_p.$$

MinT ajusta pronósticos base para imponer esta coherencia teniendo en cuenta la estructura de errores de pronóstico. Esto no es propiamente una feature, pero es particularmente relevante para el dataset extraído del Shiny porque ya se dispone de series de control provinciales y departamentales. <sup>38</sup>

## Codificación, interacciones y datos faltantes

**Interacciones.** Las epidemias rara vez se comportan como una suma completamente independiente de efectos. En el caso de covariables ambientales, los DLNM permiten representar simultáneamente no linealidad y dimensión de lag; algoritmos de árboles y boosting pueden descubrir interacciones automáticamente, mientras que para modelos lineales deben definirse explícitamente. <sup>39</sup>

En este dataset priorizaría interacciones con justificación epidemiológica:

temperatura  $\times$  lluvia,  
temperatura  $\times$  humedad,  
clima  $\times$  semana estacional,  
lag propio  $\times$  lag vecinos,  
incidencia propia  $\times$  crecimiento provincial,  
intervención  $\times$  semanas desde intervención.

Para modelos lineales regularizados comenzaría con 5–30 interacciones motivadas a priori, en lugar de generar todas las combinaciones  $O(p^2)$ . En boosting puede dejarse que el árbol aprenda gran parte de ellas, controlando profundidad; CatBoost, además, incorpora mecanismos especiales para atributos categóricos. <sup>40</sup>

Un caso particularmente interesante sería:

$$neighbor\_incidence_{t-1} \times own\_incidence_{t-1}.$$

Una incidencia elevada en distritos vecinos podría tener implicaciones distintas cuando el distrito ya se encuentra en fase epidémica frente a cuando aún tiene baja transmisión. Esta interpretación es una hipótesis de modelado que debe validarse empíricamente; los modelos espaciales de propagación proporcionan el fundamento para introducir la señal vecinal. <sup>41</sup>

**Variables categóricas.** `departamento`, `provincia`, `distrito`, `nivel` y eventualmente `semana_epidemiologica` son categóricas. Los códigos administrativos —por ejemplo, IDs o UBIGEO— no deberían suministrarse como enteros continuos porque la distancia numérica entre dos códigos no representa proximidad geográfica ni epidemiológica.

Para cardinalidad baja puede utilizarse one-hot encoding. Para muchos distritos, las alternativas principales son efectos aleatorios jerárquicos, embeddings o codificación supervisada regularizada. El esquema clásico de Micci-Barreca propuso transformaciones para categorías de alta cardinalidad; CatBoost introdujo estadísticas categóricas ordenadas precisamente para combatir el *prediction shift* y el leakage asociado a estadísticas del target calculadas ingenuamente. <sup>42</sup>

Un target encoding convencional:

$$TE(c) = E[Y \mid \text{categoría} = c]$$

es peligroso si se calcula utilizando toda la serie. Para una fila en semana  $t$ , debería construirse únicamente con semanas anteriores:

$$TE_t(c) = E[Y_s \mid c, s < t].$$

También conviene aplicar suavizado:

$$TE(c) = \frac{n_c \bar{y}_c + \lambda \mu}{n_c + \lambda},$$

con  $\lambda$  seleccionado dentro del CV. Como rango inicial podrían probarse  $\lambda \in \{5, 10, 20, 50, 100\}$ , especialmente en distritos con pocas observaciones. CatBoost evita parte de este problema mediante estadísticas ordenadas calculadas bajo permutaciones. <sup>43</sup>

**Datos faltantes.** Antes de imputar, cada ausencia debería clasificarse en al menos:

cero epidemiológico verdadero  
semana no reportada  
dato aún no consolidado  
fallo de scraping/extracción  
covariable externa faltante  
unidad geográfica inexistente/no aplicable

No deberían transformarse automáticamente todas en cero. GRU-D demostró que la máscara de faltantes y el tiempo desde la última observación pueden ser informativos; BRITS trata los valores faltantes como variables dentro de un sistema recurrente bidireccional, y SAITS utiliza autoatención para explotar dependencias temporales y entre variables. <sup>44</sup>

Para el presente caso propondría una estrategia escalonada. En conteos epidemiológicos, conservar `missing_cases_flag` y no imputar el target durante la evaluación. Para población anual puede utilizarse el valor oficial correspondiente al año o interpolación entre proyecciones cuando esté metodológicamente justificado. Para clima con brechas cortas puede utilizarse interpolación causal, estación cercana o mediana histórica, siempre ajustada solo con el training fold.

Una característica útil es:

*time\_since\_last\_observed.*

También:

*missing\_weather<sub>t</sub>, missing\_cases<sub>t</sub>, n\_missing\_last4.*

El patrón de ausencia puede contener información operativa relacionada con el sistema de vigilancia; GRU-D fue desarrollado precisamente para incorporar explícitamente máscara y tiempo transcurrido. <sup>45</sup>

BRITS y SAITS merecen una precaución especial: al explotar información bidireccional o relaciones globales son muy útiles para reconstrucción retrospectiva, pero una imputación realizada sobre todo el periodo antes de separar train/test puede transmitir información del futuro al pasado. En forecasting prospectivo, la imputación debe respetar el origen temporal o limitarse al conjunto de entrenamiento. <sup>46</sup>

## Selección de características, regularización y validación

La cantidad potencial de features crece rápidamente. Por ejemplo:

10 lags + 7 ventanas × 8 estadísticas + 12 lags climáticos × 5 variables + ...

puede generar cientos de columnas altamente correlacionadas. La selección no debería realizarse mirando su correlación con todo el target antes de dividir temporalmente el dataset, porque ello utiliza indirectamente el periodo de prueba.

**Regularización y selección.** Elastic Net combina las penalizaciones  $L_1$  y  $L_2$ :

$$\arg \min_{\beta} \left[ L(\beta) + \lambda \left( \alpha \|\beta\|_1 + \frac{1-\alpha}{2} \|\beta\|_2^2 \right) \right].$$

La combinación es especialmente apropiada cuando existen grupos de variables correlacionadas, como `lag_1`, `lag_2`, `rolling_mean_4`, `rolling_sum_4` y distintas versiones del mismo predictor meteorológico. Zou y Hastie mostraron que Elastic Net puede inducir sparsity manteniendo un efecto de agrupamiento entre predictores correlacionados; los algoritmos modernos de coordinate descent permiten calcular eficientemente trayectorias completas de regularización. <sup>47</sup>

Como grilla inicial:

$$\alpha \in \{0, 0.1, 0.25, 0.5, 0.75, 0.9, 1\}$$

y una grilla logarítmica de  $\lambda$  de unas 30–100 posiciones. Los predictores continuos deben estandarizarse dentro de cada training fold. La selección óptima de  $\alpha$ ,  $\lambda$  pertenece al CV interno y no debería hacerse con el test externo.

Para identificar features cuya selección no depende excesivamente de una partición concreta, puede utilizarse *stability selection*, que combina subsampling con un procedimiento de selección y estima con qué frecuencia entra cada variable en el modelo. Meinshausen y Bühlmann desarrollaron este enfoque para mejorar estabilidad y controlar determinadas tasas de falsos descubrimientos. <sup>48</sup>

Como criterio práctico inicial podrían conservarse variables seleccionadas en más del 60–90 % de las ventanas internas, evaluando el umbral como hiperparámetro. Para series temporales, el subsampling debería ser por bloques o ventanas temporales y no mediante filas aleatorias independientes.

Para lags meteorológicos, una estrategia conceptualmente mejor que seleccionar 12–20 columnas independientes puede ser imponer una base suave sobre los retardos mediante DLM/DLNM, reduciendo dimensionalidad y colinealidad. Gasparrini muestra que la estimación individual de muchos retardos puede tener baja precisión precisamente por la correlación entre exposiciones adyacentes. <sup>49</sup>

Una estrategia de selección razonable sería comparar mediante ablación:

```
Modelo A: calendario + lags
Modelo B: A + rolling
Modelo C: B + crecimiento/incidencia
Modelo D: C + clima
Modelo E: D + espacial
Modelo F: E + jerarquía/KPI
Modelo G: F + interacciones
```

Si una familia aumenta complejidad pero no mejora sistemáticamente los folds temporales externos, debería descartarse aunque algunas de sus variables tengan alta importancia en el entrenamiento.

**Validación temporal.** Para este dataset recomiendo *rolling-origin evaluation* con ventana creciente:

```
Train: 2019–2021 → Validate: 2022
Train: 2019–2022 → Validate: 2023
Train: 2019–2023 → Validate: 2024
Train: 2019–2024 → Test:      2025
```

Las fechas son ilustrativas; el diseño real depende de los años que se logren extraer. En series no estacionarias, la evidencia comparativa favorece procedimientos de evaluación que conservan la secuencia temporal frente a particiones que mezclan pasado y futuro. <sup>50</sup>

Si el modelo utiliza una ventana móvil en vez de creciente:

```
Train: 2019–2021 → Validate: 2022
Train: 2020–2022 → Validate: 2023
Train: 2021–2023 → Validate: 2024
```

el tamaño de ventana puede tratarse como hiperparámetro, por ejemplo 2, 3, 4 o 5 años. Una ventana corta se adapta más rápido a cambios de régimen pero descarta estacionalidad histórica; una ventana larga reduce varianza pero puede mezclar regímenes epidemiológicos antiguos y recientes.

Para  $h$ -step forecasting, debe evaluarse exactamente el horizonte operacional:

$$h \in \{1, 2, 4, 8, 12\}.$$

No es recomendable seleccionar features con  $h = 1$  y asumir que son óptimas a  $h = 12$ . En el estudio de Iquitos se evaluaron precisamente distintos horizontes semanales hasta 12 semanas, encontrándose diferencias según horizonte y conjunto de predictores. <sup>51</sup>

**Nested time-series CV.** El bucle externo estima la capacidad de generalización; el interno selecciona features e hiperparámetros:

```
OUTER TRAIN
├─ inner train 1 → validation 1
├─ inner train 2 → validation 2
└─ inner train 3 → validation 3
    ↓
  elegir features/hiperparámetros
    ↓
refit sobre todo OUTER TRAIN
    ↓
OUTER TEST
```

Cawley y Talbot demostraron que la propia selección de modelos e hiperparámetros puede sobreajustar el criterio de evaluación; separar la selección de la estimación final mediante un esquema anidado evita utilizar el mismo conjunto para ambas decisiones. Para series temporales, los bucles deben preservar además el orden cronológico. <sup>52</sup>

Para el panel geográfico, **todos los distritos deberían compartir la misma fecha de corte**. No sería apropiado entrenar con diciembre de 2024 de un distrito mientras se evalúa junio de 2024 de otro si el objetivo es simular lo que el sistema habría conocido en junio.

También recomiendo una evaluación secundaria de generalización espacial:

```
Temporal CV:
  mismos distritos, semanas futuras
```

Spatial CV:  
algunos distritos completamente excluidos

La primera responde “¿puedo pronosticar las siguientes semanas en distritos conocidos?”. La segunda responde “¿puedo generalizar a un distrito con poca o ninguna historia?”. El segundo escenario es especialmente informativo para valorar embeddings, pooling provincial y variables espaciales. Los modelos BYM/BYM2 y los enfoques endémico-epidémicos ofrecen fundamentos para compartir señal entre unidades geográficas relacionadas. <sup>22</sup>

Respecto a métricas, para conteos conviene reportar al menos MAE, RMSE y una métrica probabilística coherente con la distribución cuando se produzcan pronósticos probabilísticos; para detección de brotes pueden añadirse sensibilidad, especificidad o MCC. El trabajo de Benedum et al. utilizó MAE para conteos y MCC para predicción de brotes, lo que permite separar la capacidad de predecir magnitud de la capacidad de anticipar estados epidémicos. <sup>51</sup>

## Matriz de características e implementación recomendada

La siguiente matriz sintetiza las principales features candidatas. Los rangos son **puntos de partida para búsqueda mediante CV temporal**, no constantes epidemiológicas universales.

| Feature                       | Tipo        | Cálculo                | Hiperparámetros iniciales | Beneficio esperado     | Cos   |
|-------------------------------|-------------|------------------------|---------------------------|------------------------|-------|
| <code>cases_lag_k</code>      | Temporal    | $Y_{t-k}$              | k=1,2,3,4,6,8,12,13,26,52 | Persistencia y memoria | Bajo  |
| <code>rolling_mean_w</code>   | Temporal    | media de $Y_{t-w:t-1}$ | w=2,4,8,13,26             | Suaviza ruido          | Bajo  |
| <code>rolling_std_w</code>    | Volatilidad | SD histórica           | w=4,8,13,26               | Detecta inestabilidad  | Bajo  |
| <code>rolling_median_w</code> | Robusta     | mediana                | w=4,8,13                  | Resiste outliers       | Bajo  |
| <code>rolling_q25/q75</code>  | Robusta     | cuantiles              | w=8,13,26                 | Contexto distributivo  | Medio |
| <code>rolling_max</code>      | Pico        | máximo pasado          | w=4,8,13                  | Memoria de picos       | Bajo  |
| <code>diff_1</code>           | Crecimiento | $Y_{t-1} - Y_{t-2}$    | k=1                       | Velocidad inmediata    | Bajo  |
| <code>diff_4</code>           | Crecimiento | $Y_{t-1} - Y_{t-5}$    | k=4                       | Cambio mensual         | Bajo  |
| <code>log_growth</code>       | Crecimiento | $\Delta \log(1+Y)$     | k=1,2,4                   | Estable con ceros      | Bajo  |

| Feature                       | Tipo           | Cálculo                      | Hiperparámetros<br>iniciales | Beneficio<br>esperado          | Cos           |
|-------------------------------|----------------|------------------------------|------------------------------|--------------------------------|---------------|
| <code>acceleration</code>     | Crecimiento    | segunda diferencia           | 1–4 sem.                     | Cambio de<br>pendiente         | Bajo          |
| <code>incidence_100k</code>   | Epidemiológica | casos/población×100k         | población anual              | Comparabilidad                 | Bajo          |
| <code>log_population</code>   | Exposición     | log(N)                       | —                            | Offset para<br>conteos         | Bajo          |
| <code>cum_ytd</code>          | Acumulada      | sum hasta t–1                | anual                        | Fase de<br>temporada           | Bajo          |
| <code>recent4_prev4</code>    | Régimen        | suma4/suma4 anterior         | c=0.5–1                      | Aceleración<br>robusta         | Bajo          |
| <code>fourier_k</code>        | Estacional     | sin/cos                      | K=1–6                        | Estacionalidad<br>parsimoniosa | Bajo          |
| <code>week_category</code>    | Calendario     | categoría semana             | 52/53 niveles                | No linealidad<br>flexible      | Medio         |
| <code>trend_lag</code>        | Tendencia      | STL/MSTL causal              | periodo≈52                   | Nivel<br>subyacente            | Medio         |
| <code>remainder_z</code>      | Anomalía       | residuo/tendencia<br>robusta | w=13–52                      | Exceso<br>inesperado           | Medio         |
| <code>changepoint_flag</code> | Régimen        | PELT/BOCPD                   | penalización/hazard          | Detecta<br>transiciones        | Medio<br>alto |
| <code>weather_lag_k</code>    | Externa        | $X_{t-k}$                    | k=1–12/16                    | Efectos<br>retardados          | Medio         |
| <code>weather_roll</code>     | Externa        | roll 4–12 sem.               | 4,8,12                       | Exposición<br>acumulada        | Medio         |
| <code>neighbor_lag</code>     | Espacial       | $WY_{t-k}$                   | k=1–4                        | Propagación<br>regional        | Medio         |
| <code>province_other</code>   | Jerárquica     | provincia–distrito           | lag 1–4                      | Contexto<br>provincial         | Bajo          |
| <code>department_other</code> | Jerárquica     | departamento–provincia       | lag 1–4                      | Régimen<br>regional            | Bajo          |
| <code>district_share</code>   | Ratio          | distrito/provincia           | lag 1–4                      | Peso relativo                  | Bajo          |
| <code>mobility_import</code>  | Espacial       | $\sum w_{ji}I_j$             | lag 1–4                      | Casos<br>importados            | Alto          |

| Feature                       | Tipo                  | Cálculo            | Hiperparámetros<br>iniciales | Beneficio<br>esperado         | Cos   |
|-------------------------------|-----------------------|--------------------|------------------------------|-------------------------------|-------|
| <code>intervention</code>     | Política<br>sanitaria | 0/1, pulse, slope  | delays 0–8                   | Cambio<br>estructural         | Bajo  |
| <code>holiday</code>          | Calendario            | indicador          | lag 0–2                      | Reporte/<br>calendario        | Bajo  |
| <code>missing_flag</code>     | Calidad               | 0/1                | —                            | Missingness<br>informativo    | Bajo  |
| <code>weeks_since_obs</code>  | Calidad               | tiempo desde dato  | —                            | Calidad del<br>reporte        | Bajo  |
| <code>geo_encoding</code>     | Categórica            | one-hot/ordered TE | smoothing 5–100              | Heterogeneidad<br>territorial | Medio |
| <code>kpi_lagged</code>       | Shiny/KPI             | KPI histórico      | lag $\geq 1$                 | Contexto<br>adicional         | Bajo  |
| <code>weather × season</code> | Interacción           | producto           | K/clima seleccionados        | Efecto<br>estacional clima    | Medio |
| <code>own × neighbor</code>   | Interacción           | producto           | lags 1–4                     | Intensidad<br>espacial        | Medio |

Las familias de retardos y ventanas están respaldadas por la literatura de DLM/DLNM y forecasting de dengue; Fourier, STL/MSTL y TBATS respaldan la representación de periodicidad; los modelos endémico-epidémicos y BYM/BYM2 respaldan la estructura espacial; y Elastic Net/stability selection ofrecen mecanismos apropiados para manejar la expansión y correlación del espacio de features. <sup>53</sup>

**Implementación causal de lags, ventanas y crecimiento en pandas.** El siguiente ejemplo supone un panel con una fila por distrito y semana. Para una tarea de forecasting las ventanas se desplazan antes de calcularse para garantizar que no incorporen el valor de la propia semana objetivo.

```
import numpy as np
import pandas as pd

def build_temporal_features(
    df: pd.DataFrame,
    target: str = "casos",
    geo_col: str = "geo_id",
) -> pd.DataFrame:
    """
    Construye características temporales estrictamente basadas
    en observaciones anteriores de cada unidad geográfica.
```

```

Columnas esperadas:
    geo_id, ano, semana, casos
Opcionales:
    poblacion
"""
out = df.copy()

out = out.sort_values(
    [geo_col, "ano", "semana"]
).reset_index(drop=True)

g = out.groupby(geo_col, sort=False)[target]

# Lags
lags = [1, 2, 3, 4, 6, 8, 12, 13, 26, 52]
for lag in lags:
    out[f"{target}_lag_{lag}"] = g.shift(lag)

# Rolling features: shift(1) evita utilizar el valor actual.
windows = [2, 4, 8, 13, 26]

for w in windows:
    out[f"{target}_mean_{w}"] = (
        out.groupby(geo_col)[target]
        .transform(
            lambda s: s.shift(1)
            .rolling(w, min_periods=max(2, w // 2))
            .mean()
        )
    )

    out[f"{target}_std_{w}"] = (
        out.groupby(geo_col)[target]
        .transform(
            lambda s: s.shift(1)
            .rolling(w, min_periods=max(2, w // 2))
            .std()
        )
    )

    out[f"{target}_median_{w}"] = (
        out.groupby(geo_col)[target]
        .transform(
            lambda s: s.shift(1)
            .rolling(w, min_periods=max(2, w // 2))
            .median()
        )
    )

```

```

    )

    out[f"{target}_max_{w}"] = (
        out.groupby(geo_col)[target]
        .transform(
            lambda s: s.shift(1)
            .rolling(w, min_periods=max(2, w // 2))
            .max()
        )
    )

    out[f"{target}_q25_{w}"] = (
        out.groupby(geo_col)[target]
        .transform(
            lambda s: s.shift(1)
            .rolling(w, min_periods=max(2, w // 2))
            .quantile(0.25)
        )
    )

    out[f"{target}_q75_{w}"] = (
        out.groupby(geo_col)[target]
        .transform(
            lambda s: s.shift(1)
            .rolling(w, min_periods=max(2, w // 2))
            .quantile(0.75)
        )
    )

# Crecimiento causal
y1 = g.shift(1)
y2 = g.shift(2)
y5 = g.shift(5)

out["diff_1"] = y1 - y2
out["diff_4"] = y1 - y5

# Transformación estable ante ceros
out["log_growth_1"] = np.log1p(y1) - np.log1p(y2)
out["log_growth_4"] = np.log1p(y1) - np.log1p(y5)

# Aceleración
out["acceleration_1"] = (
    (g.shift(1) - g.shift(2))
    - (g.shift(2) - g.shift(3))
)

return out

```

Este esquema corresponde conceptualmente a la utilización de información histórica de vigilancia y de retardos distribuidos, pero evita el error frecuente de calcular el rolling incluyendo el dato contemporáneo.

54

### Fourier y acumulados.

```
def add_periodic_and_cumulative_features(
    df: pd.DataFrame,
    geo_col: str = "geo_id",
    target: str = "casos",
    harmonics: int = 3,
    annual_period: float = 365.2425 / 7,
) -> pd.DataFrame:
    out = df.copy()

    out = out.sort_values(
        [geo_col, "ano", "semana"]
    ).reset_index(drop=True)

    # Índice temporal continuo.
    # Para producción es preferible derivarlo de una fecha semanal oficial.
    out["time_index"] = (
        out.groupby(geo_col).cumcount()
    )

    # Términos Fourier
    for k in range(1, harmonics + 1):
        angle = (
            2.0
            * np.pi
            * k
            * out["time_index"]
            / annual_period
        )

        out[f"fourier_sin_{k}"] = np.sin(angle)
        out[f"fourier_cos_{k}"] = np.cos(angle)

    # Acumulado anual hasta la semana anterior
    out["cum_ytd_lag1"] = (
        out.groupby([geo_col, "ano"])[target]
        .transform(
            lambda s: s.shift(1)
            .fillna(0)
            .cumsum()
        )
    )
```

```
return out
```

Las representaciones trigonométricas son una alternativa parsimoniosa a crear una dummy por cada semana y están estrechamente relacionadas con la formulación de estacionalidad compleja empleada por TBATS. <sup>55</sup>

### **Incidencia y exposición poblacional.**

```
def add_population_features(
    df: pd.DataFrame,
    target: str = "casos",
    population_col: str = "poblacion",
) -> pd.DataFrame:
    out = df.copy()

    valid_population = out[population_col] > 0

    out["incidencia_100k"] = np.where(
        valid_population,
        out[target] / out[population_col] * 100_000,
        np.nan,
    )

    out["log_population"] = np.where(
        valid_population,
        np.log(out[population_col]),
        np.nan,
    )

    return out
```

Para una regresión Poisson/binomial negativa, `log_population` puede utilizarse como offset; si el objetivo es comparar territorialmente el riesgo observado, `incidencia_100k` es una feature o variable descriptiva natural. Las poblaciones de referencia deberían provenir de estimaciones oficiales consistentes entre niveles administrativos. <sup>56</sup>

**Contexto provincial leave-one-out.** Esta transformación está particularmente adaptada a la estructura de los datos obtenidos de Shiny:

```
def add_hierarchical_features(df: pd.DataFrame) -> pd.DataFrame:
    """
    Espera una tabla exclusivamente a nivel distrital.
    """
    out = df.copy()
```

```

keys_week = [
    "departamento",
    "provincia",
    "ano",
    "semana",
]

# Total provincial observado en cada semana
out["province_total"] = (
    out.groupby(keys_week)["casos"]
    .transform("sum")
)

# Casos del resto de la provincia
out["province_other"] = (
    out["province_total"] - out["casos"]
)

# Solo utilizamos información de semanas anteriores
out["province_other_lag1"] = (
    out.groupby("geo_id")["province_other"]
    .shift(1)
)

out["province_other_lag4"] = (
    out.groupby("geo_id")["province_other"]
    .shift(4)
)

return out

```

La ventaja frente a usar directamente `province_total_lag1` es que separa mejor la señal distrital de la señal del resto de la provincia. Es una construcción específica propuesta para este dataset, consistente con la idea más general de compartir información espacial y jerárquica entre unidades epidemiológicas. <sup>57</sup>

**Lag espacial con NumPy.** Si  $W$  es una matriz de adyacencia normalizada y  $Y$  tiene semanas por filas y distritos por columnas:

```

import numpy as np

def row_normalize(W: np.ndarray) -> np.ndarray:
    W = np.asarray(W, dtype=float)

    row_sum = W.sum(axis=1, keepdims=True)

```

```

    return np.divide(
        W,
        row_sum,
        out=np.zeros_like(W),
        where=row_sum != 0,
    )

def spatial_lag(Y: np.ndarray, W: np.ndarray) -> np.ndarray:
    """
    Y: shape (n_weeks, n_districts)
    W: shape (n_districts, n_districts)

    Devuelve el promedio ponderado de los vecinos
    de la semana ANTERIOR.
    """
    Wn = row_normalize(W)

    neighbor_same_week = Y @ Wn.T

    result = np.full_like(
        neighbor_same_week,
        fill_value=np.nan,
        dtype=float,
    )

    # El valor para t usa vecinos en t-1.
    result[1:] = neighbor_same_week[:-1]

    return result

```

Una matriz  $W$  basada en fronteras, distancias o flujos permite aproximar la conectividad territorial; los modelos de propagación de enfermedades infecciosas proporcionan precedentes directos para este tipo de dependencia espacial. <sup>58</sup>

### Anomalía robusta.

```

def add_robust_anomaly(
    df: pd.DataFrame,
    geo_col: str = "geo_id",
    target: str = "casos",
    window: int = 13,
) -> pd.DataFrame:
    out = df.copy()

```

```

def compute(series: pd.Series) -> pd.DataFrame:
    past = series.shift(1)

    median = past.rolling(
        window,
        min_periods=max(4, window // 2),
    ).median()

    mad = past.rolling(
        window,
        min_periods=max(4, window // 2),
    ).apply(
        lambda x: np.median(
            np.abs(x - np.median(x))
        ),
        raw=True,
    )

    z = (past - median) / (
        1.4826 * mad + 1e-8
    )

    return pd.DataFrame(
        {
            "rolling_median": median,
            "robust_z": z,
        },
        index=series.index,
    )

features = (
    out.groupby(geo_col, group_keys=False)[target]
    .apply(compute)
)


out["robust_z"] = features["robust_z"]
out["anomaly_3sigma"] = (
    out["robust_z"] > 3
).astype("int8")

return out

```

Esto no sustituye un algoritmo epidemiológico formal de detección de brotes como Farrington, pero constituye una señal predictiva económica que puede suministrarse al modelo junto con indicadores más sofisticados de changepoint. <sup>59</sup>

El pipeline completo recomendado es:



La regla central del diagrama es que **el split temporal precede a cualquier transformación que aprenda información de los datos**. Esto incluye imputación, target encoding, selección de variables, escalamiento, STL, changepoint detection y optimización de hiperparámetros. La evidencia sobre evaluación temporal y sesgo de selección respalda separar estos procesos para obtener una estimación realista de generalización.

60

Para el caso concreto del scraper mostrado, implementaría primero un **Feature Set A** limitado y altamente interpretable:

```

cases_lag_1
cases_lag_2
cases_lag_3
cases_lag_4
cases_lag_8
cases_lag_12

cases_mean_2
cases_mean_4
cases_mean_8
cases_mean_13

cases_std_4

```

```

cases_std_8

diff_1
diff_4
log_growth_1
acceleration_1

incidencia_100k_lag1
fourier_sin_1
fourier_cos_1
fourier_sin_2
fourier_cos_2

cum_ytd_lag1
recent4_prev4
robust_z

province_other_lag1
province_other_lag4

```

Ese conjunto debería constituir el **baseline serio** antes de añadir meteorología, movilidad, STL o centenares de interacciones. Los antecedentes de vigilancia han demostrado ser competitivos para forecasting semanal de dengue, incluido Iquitos, mientras que las expansiones mediante clima y contexto espacial deben demostrar su valor incremental fuera de muestra. <sup>61</sup>

Después añadiría un **Feature Set B externo**:

```

temperature_lag_1 ... lag_12
rainfall_lag_1 ... lag_12
humidity_lag_1 ... lag_12

temperature_mean_4 / 8 / 12
rainfall_sum_4 / 8 / 12
humidity_mean_4 / 8 / 12

neighbor_incidence_lag_1 / 2 / 4
neighbor_growth_lag_1

intervention_flag
weeks_since_intervention
holiday_flag

```

En vez de conservar automáticamente todos esos lags meteorológicos, evaluaría Elastic Net o DLNM para reducirlos a una representación más estable. <sup>62</sup>

Un **Feature Set C** debería reservarse para una extracción multianual suficientemente larga:

```

cases_lag_26
cases_lag_52

rolling_26
rolling_52

STL_trend
STL_seasonal
STL_remainder

weeks_since_changepoint
BOCPD_probability

multi-year week baseline
same_week_previous_year
same_week_previous_2years

```

Estas variables no son recomendables como núcleo del modelo mientras exista únicamente un ciclo anual. STL/MSTL, Fourier de orden alto, `lag_52` y comparación “misma semana del año anterior” adquieren verdadero valor una vez que la extracción contiene varios años epidemiológicos. <sup>14</sup>

Entre las fuentes primarias especialmente relevantes para documentar metodológicamente este informe se encuentran: Gasparrini, Armstrong y Kenward, *Distributed lag non-linear models*, con su formulación de efectos no lineales y retardados ([DOI 10.1002/sim.3940](https://doi.org/10.1002/sim.3940)); Benedum et al., *Weekly dengue forecasts in Iquitos, Peru; San Juan, Puerto Rico; and Singapore* ([DOI 10.1371/journal.pntd.0008710](https://doi.org/10.1371/journal.pntd.0008710)); De Livera, Hyndman y Snyder, *Forecasting Time Series With Complex Seasonal Patterns Using Exponential Smoothing* ([DOI 10.1198/jasa.2011.tm09771](https://doi.org/10.1198/jasa.2011.tm09771)); Bandara, Hyndman y Bergmeir, *MSTL* ([DOI 10.1504/IJOR.2025.143957](https://doi.org/10.1504/IJOR.2025.143957)); Meyer y Held, *Power-law models for infectious disease spread*; Wickramasuriya, Athanasopoulos y Hyndman, *Optimal Forecast Reconciliation* ([DOI 10.1080/01621459.2018.1448825](https://doi.org/10.1080/01621459.2018.1448825)); Zou y Hastie, *Elastic Net* ([DOI 10.1111/j.1467-9868.2005.00503.x](https://doi.org/10.1111/j.1467-9868.2005.00503.x)); Cerqueira, Torgo y Mozetič, *Evaluating time series forecasting models* ([DOI 10.1007/s10994-020-05910-7](https://doi.org/10.1007/s10994-020-05910-7)); Riebler et al., *An intuitive Bayesian spatial model for disease mapping* ([DOI 10.1177/0962280216660421](https://doi.org/10.1177/0962280216660421)); y Du, Côté y Liu, *SAITS* ([DOI 10.1016/j.eswa.2023.119619](https://doi.org/10.1016/j.eswa.2023.119619)). <sup>63</sup>

<sup>1</sup> <sup>11</sup> <sup>13</sup> <sup>51</sup> <sup>61</sup> <https://pmc.ncbi.nlm.nih.gov/articles/PMC7567393/>  
<https://pmc.ncbi.nlm.nih.gov/articles/PMC7567393/>

<sup>2</sup> <sup>14</sup> <https://research.monash.edu/en/publications/mstl-a-seasonal-trend-decomposition-algorithm-for-time-series-wit/>  
<https://research.monash.edu/en/publications/mstl-a-seasonal-trend-decomposition-algorithm-for-time-series-wit/>

<sup>3</sup> <sup>12</sup> <sup>15</sup> <sup>16</sup> <sup>30</sup> <sup>31</sup> <sup>39</sup> <sup>49</sup> <sup>53</sup> <sup>54</sup> <sup>62</sup> <sup>63</sup> <https://pmc.ncbi.nlm.nih.gov/articles/PMC2998707/>  
<https://pmc.ncbi.nlm.nih.gov/articles/PMC2998707/>

<sup>4</sup> <sup>50</sup> <https://arxiv.org/abs/1905.11744>  
<https://arxiv.org/abs/1905.11744>

5 40 43 <https://arxiv.org/abs/1706.09516>

<https://arxiv.org/abs/1706.09516>

6 8 28 32 60 <https://link.springer.com/article/10.1007/s10994-020-05910-7>

<https://link.springer.com/article/10.1007/s10994-020-05910-7>

7 56 <https://www.inei.gob.pe/>

<https://www.inei.gob.pe/>

9 44 45 <https://www.nature.com/articles/s41598-018-24271-9>

<https://www.nature.com/articles/s41598-018-24271-9>

10 38 <https://www.tandfonline.com/doi/full/10.1080/01621459.2018.1448825>

<https://www.tandfonline.com/doi/full/10.1080/01621459.2018.1448825>

17 55 <https://www.tandfonline.com/doi/abs/10.1198/jasa.2011.tm09771>

<https://www.tandfonline.com/doi/abs/10.1198/jasa.2011.tm09771>

18 29 <https://www.jstatsoft.org/v027/i03>

<https://www.jstatsoft.org/v027/i03>

19 20 <https://pubmed.ncbi.nlm.nih.gov/17476782/>

<https://pubmed.ncbi.nlm.nih.gov/17476782/>

21 34 35 41 57 58 <https://projecteuclid.org/journals/annals-of-applied-statistics/volume-8/issue-3/Power-law-models-for-infectious-disease-spread/10.1214/14-AOAS743.full>

<https://projecteuclid.org/journals/annals-of-applied-statistics/volume-8/issue-3/Power-law-models-for-infectious-disease-spread/10.1214/14-AOAS743.full>

22 36 37 <https://link.springer.com/article/10.1007/BF00116466>

<https://link.springer.com/article/10.1007/BF00116466>

23 <https://pubmed.ncbi.nlm.nih.gov/24043437/>

<https://pubmed.ncbi.nlm.nih.gov/24043437/>

24 25 59 <https://onlinelibrary.wiley.com/doi/10.1002/sim.5595>

<https://onlinelibrary.wiley.com/doi/10.1002/sim.5595>

26 <https://search.proquest.com/openview/cc5001e8a0978a6c029ae9a41af00f21/1?pq-origsite=gscholar%26cbl%3D105444>

<https://search.proquest.com/openview/cc5001e8a0978a6c029ae9a41af00f21/1?pq-origsite=gscholar%26cbl%3D105444>

27 <https://arxiv.org/abs/1101.1438>

<https://arxiv.org/abs/1101.1438>

33 <https://pmc.ncbi.nlm.nih.gov/articles/PMC12657288/>

<https://pmc.ncbi.nlm.nih.gov/articles/PMC12657288/>

42 <https://dl.acm.org/doi/10.1145/507533.507538>

<https://dl.acm.org/doi/10.1145/507533.507538>

46 <https://arxiv.org/abs/1805.10572>

<https://arxiv.org/abs/1805.10572>

47 <https://academic.oup.com/jrsssb/article/67/2/301/7109482>

<https://academic.oup.com/jrsssb/article/67/2/301/7109482>

<sup>48</sup> <https://academic.oup.com/jrsssb/article/72/4/417/7076513>  
<https://academic.oup.com/jrsssb/article/72/4/417/7076513>

<sup>52</sup> <https://dl.acm.org/doi/10.5555/1756006.1859921>  
<https://dl.acm.org/doi/10.5555/1756006.1859921>